Как поправка на предысторию находит эффект

Разбор на десяти игроках: от исходных данных до итогового вывода

Задача

Проверяется изменение в игре. Десять игроков случайно поделены на две группы: A видит старую версию, B новую. Метрика — время в игре за две недели.

Это учебный пример, поэтому истинный ответ известен заранее: **в группе B время в игре увеличено ровно на 5%**. В настоящем эксперименте этого никто не знает, здесь же это позволяет проверить, какой способ анализа дает верный ответ.

Для каждого игрока есть два числа: сколько он играл за две недели до теста (X) и сколько за две недели теста (Y).

Группа	X, до теста	Y, во время теста
A	200	180,0
A	150	127,5
A	60	70,0
A	40	40,0
A	20	35,0
B	180	168,0
B	120	110,2
B	50	70,9
B	30	34,1
B	10	28,9

Способ 1. Сравнить средние напрямую

Складываем Y по каждой группе и делим на пять.

A: 90,5 минуты B: 82,4 минуты разница −8,1 минуты, то есть −8,9%

Вывод получается такой: изменение сделало хуже. Он неверен, потому что истинный эффект положительный.

Где ошибка

Посмотрите на столбец X. Среднее время до теста: в группе A 94 минуты, в группе B 78 минут. Монетка случайно собрала в группу A игроков, которые и раньше играли больше. Эти 16 минут разницы существовали до всякого изменения, но прямое сравнение приписывает их изменению. Реальный прирост в 5% оказался перекрыт случайным перекосом состава групп.

Способ 2. Поправка на предысторию

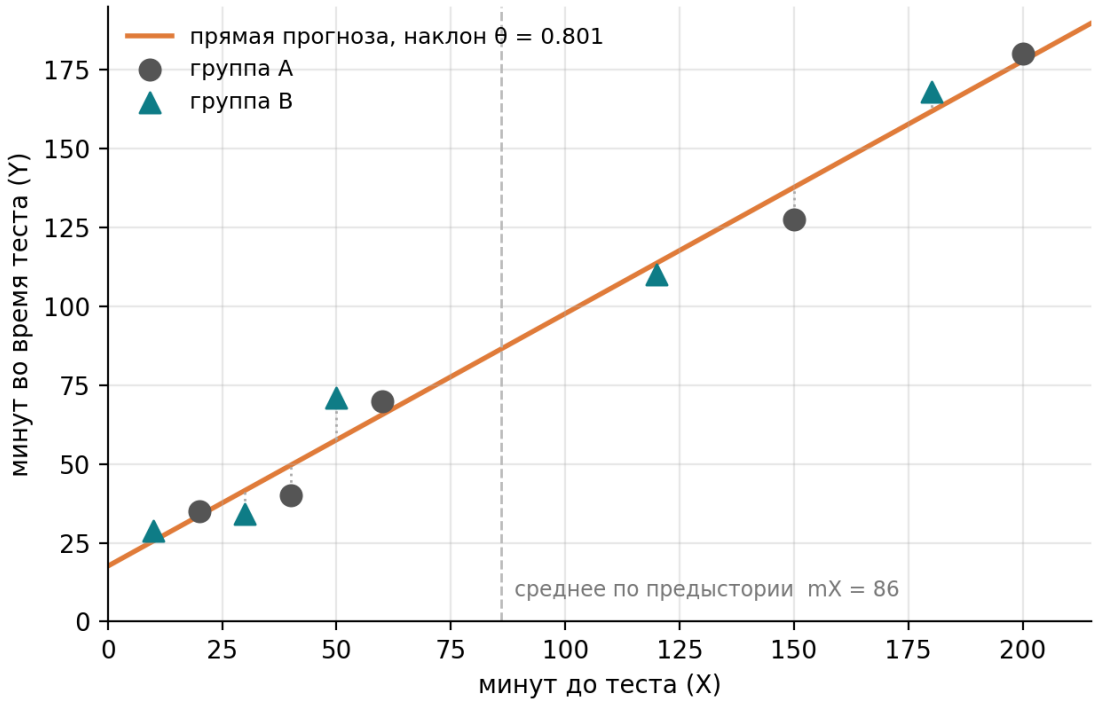
Идея: из метрики каждого игрока вычесть ту часть, которую можно было предсказать заранее по его поведению до теста. Тогда в сравнении останется только то, чего по прошлому предсказать было нельзя, — а именно там и проявляется эффект.

Шаг 1. Найти, насколько прошлое предсказывает настоящее

По всем десяти игрокам строится прямая, которая ближе всего лежит к точкам. Ее наклон обозначается θ и вычисляется как отношение ковариации X и Y к дисперсии X. На этих данных:

$$\theta = 0{,}801$$

Смысл: каждая минута, сыгранная до теста, предсказывает примерно 0,8 минуты во время теста. Не минуту в минуту: тот, кто в прошлый период показал рекорд, обычно немного опускается, а кто играл мало — немного поднимается.



Облако точек и прямая прогноза. Пунктиром показано отклонение каждого игрока от прямой: это та часть, которую по предыстории предсказать нельзя.

Шаг 2. Посчитать поправку каждому игроку

Среднее по предыстории всех десяти игроков: mX = 86 минут. Поправка считается по формуле

$$Y_{adj} = Y - \theta\,(X - m_X)$$

Первый игрок группы A. До теста он играл 200 минут, это на 114 минут больше среднего. Умножаем на 0,801 и получаем 91,3: ровно настолько от него ожидали результата выше обычного. Вычитаем этот ожидаемый бонус: 180,0 − 91,3 = 88,7.

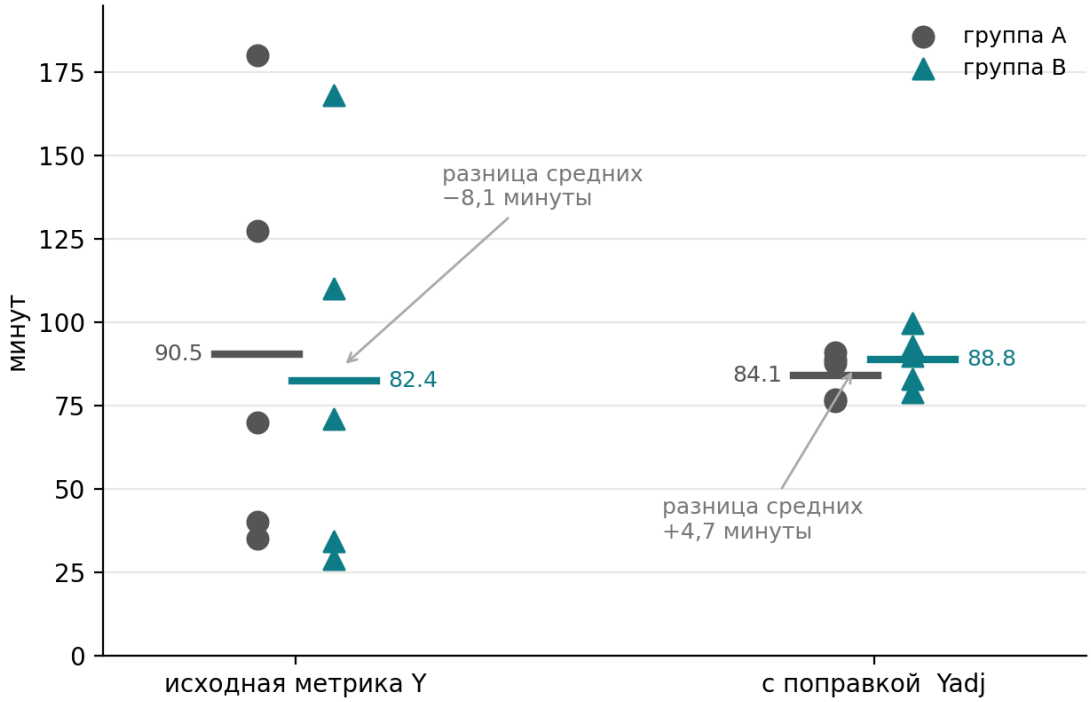
Последний игрок группы B. До теста он играл 10 минут, это на 76 минут меньше среднего. Поправка работает в обратную сторону и добавляет 60,9 минуты: 28,9 + 60,9 = 89,8.

Группа	X	Y	Поправка	Y_{adj}
A	200	180,0	−91,3	88,7
A	150	127,5	−51,3	76,2
A	60	70,0	+20,8	90,8
A	40	40,0	+36,8	76,8
A	20	35,0	+52,9	87,9
B	180	168,0	−75,3	92,7
B	120	110,2	−27,2	83,0
B	50	70,9	+28,8	99,7
B	30	34,1	+44,8	78,9
B	10	28,9	+60,9	89,8

Шаг 3. Сравнить средние скорректированных значений

A: 84,1 B: 88,8 разница +4,7 минуты, то есть +5,2%

Истинный эффект составлял 5%. Поправка его нашла, а прямое сравнение дало ответ противоположного знака.



Слева исходная метрика, справа она же после поправки. Разброс сжимается, а разница между группами меняет знак на верный.

Что именно произошло

Исчез разброс между игроками. В столбце Y значения идут от 28,9 до 180 минуты, разница в шесть раз. В столбце Y_{adj} все укладывается между 76 и 100. Стандартное отклонение упало с 56,8 до 7,6 минуты.

Это видно и по смыслу величины. Y_{adj} — уже не «сколько человек наиграл», а «насколько он отклонился от ожидаемого для себя». По такой шкале активный и пассивный игроки сопоставимы.

Учтен перекос состава. Игрокам группы A, которым досталась более сильная предыстория, поправка срезала больше. Преимущество, не связанное с изменением, из сравнения ушло.

Почему это законно

Поправка строится вслепую: формула использует только предысторию и не знает, кто в какой группе. Предыстория зафиксирована до того, как монетка поделила игроков, поэтому в среднем она одинакова в обеих группах, и вычитание не сдвигает разницу между ними — только убирает разброс вокруг нее.
Отсюда же главное требование к данным: в поправку нельзя брать ничего, измеренного после старта теста. Такая величина уже затронута изменением, и поправка вычтет часть настоящего эффекта вместе с шумом.

Оговорка про масштаб

Десять игроков подобраны так, чтобы арифметику можно было проверить вручную. Связь между периодами здесь очень сильная, корреляция 0,99, поэтому разброс падает почти в 50 раз. На реальных данных корреляция около 0,8, и дисперсия снижается примерно в 2,5 раза. Механика та же, выигрыш скромнее.