Коррекция по нескольким признакам

Продолжение разбора: что меняется, когда кроме предыстории известно что-то еще

Что было раньше

В предыдущем разборе поправка строилась на одном признаке — времени в игре до теста. Прогноз давала прямая, а скорректированная метрика считалась как Y минус отклонение прогноза от его среднего. Это классический CUPED.

Теперь к предыстории добавляется второй признак: устройство игрока. Остальное в данных то же самое, истинный эффект по-прежнему **+5% в группе B**.

Данные

Группа	X, до теста	Устройство	Y, во время теста
A	200	iOS	201,0
A	150	iOS	151,5
A	60	Android	70,0
A	40	iOS	75,0
A	20	Android	30,0
B	180	Android	169,0
B	120	iOS	141,8
B	50	Android	54,1
B	30	Android	48,8
B	10	Android	24,7

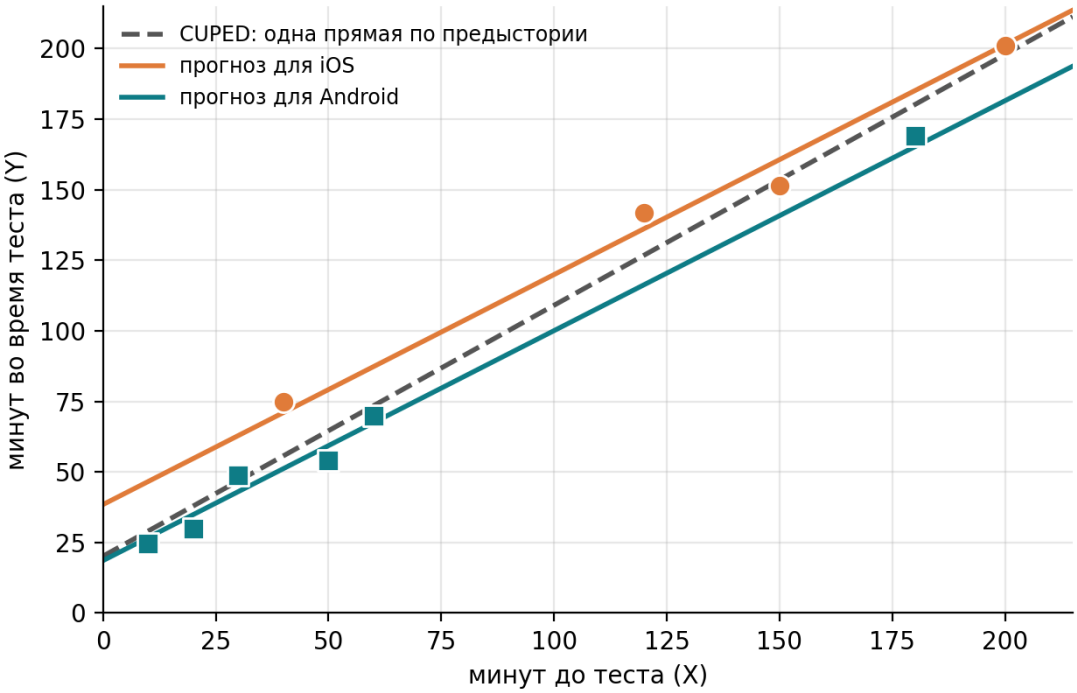
Почему одной предыстории мало

Два наблюдения, которые видно прямо в таблице.

Устройство влияет на метрику само по себе. Игрок с 40 минутами предыстории на iOS наиграл 75 минут, а игрок с 50 минутами на Android — только 54. При сопоставимой предыстории владельцы iOS в этих данных играют больше.

Устройства распределились по группам неравномерно. В группе A на iOS трое из пяти, в группе B — один из пяти. Монетка так легла. Это второй перекос состава, помимо перекоса по предыстории, который мы разбирали раньше.

CUPED видит только предысторию, поэтому разницу по устройствам он не учитывает и часть перекоса остается в сравнении.



Кружки — iOS, квадраты — Android. Одна прямая (пунктир) проходит между двумя облаками и систематически промахивается: для iOS занижает прогноз, для Android завышает. Две прямые описывают данные точнее.

Как строится прогноз по двум признакам

Вместо прямой подбирается формула с тремя числами. Метод тот же: коэффициенты выбираются так, чтобы сумма квадратов промахов была наименьшей. На этих данных получается

$$\text{прогноз} = 18{,}57 + 0{,}81 \times X + 19{,}86 \times \text{iOS}$$

Как это читать:

18,57 — базовый уровень: прогноз для игрока на Android с нулевой предысторией.

0,81 — вклад предыстории: каждая минута до теста предсказывает 0,81 минуты во время теста.

19,86 — надбавка за iOS. Она добавляется только тем, у кого в столбце устройства стоит iOS, и означает: при равной предыстории такой игрок наиграет примерно на 20 минут больше.

Геометрически это две параллельные прямые с одинаковым наклоном и разным уровнем. Устройство не число, поэтому в формулу оно входит как отметка: единица для iOS и ноль для Android.

Прогноз и поправка для каждого игрока

Поправка считается так же, как раньше, только прогноз теперь свой у каждого игрока с учетом устройства:

$$Y_{adj} = Y - (\text{прогноз} - \text{средний прогноз})$$

Средний прогноз по всем десяти игрокам равен 96,6 минуты.

Группа	X	Устройство	Y	Прогноз	Y_{adj}
A	200	iOS	201,0	201,4	96,2
A	150	iOS	151,5	160,7	87,4
A	60	Android	70,0	67,5	99,1
A	40	iOS	75,0	71,0	100,6
A	20	Android	30,0	34,9	91,7
B	180	Android	169,0	165,2	100,3
B	120	iOS	141,8	136,2	102,2
B	50	Android	54,1	59,3	91,4
B	30	Android	48,8	43,0	102,4
B	10	Android	24,7	26,7	94,6

Первая строка: игрок наиграл 201 минуту, прогноз для него 201,4. Он отработал ровно как ожидалось, поэтому после поправки получает значение около среднего. Четвертая строка: при скромной предыстории в 40 минут игрок наиграл 75 — заметно выше прогноза 71,0, и после поправки оказывается выше среднего.

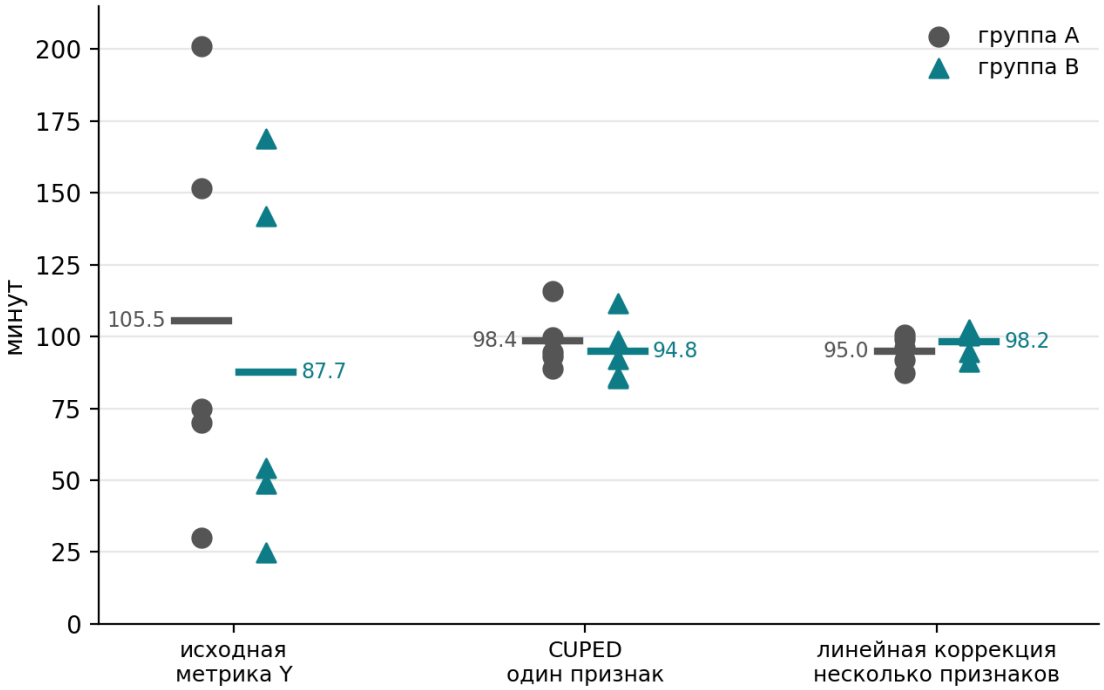
Результат

A: 95,0 B: 98,2 разница +3,2 минуты, то есть +3,0%

Способ анализа	Оценка эффекта	Стандартное отклонение
Прямое сравнение средних	−16,9%	63,3
CUPED, один признак	−3,4%	10,2
Линейная коррекция, два признака	+3,0%	5,2
Истинный эффект	+5,0%	—

Каждый шаг приближает оценку к истине и уменьшает разброс. Прямое сравнение дает ответ неверного знака. CUPED убирает перекос по предыстории, но перекос по устройствам остается, и оценка все еще отрицательная. Коррекция по двум признакам убирает оба перекоса.

До истинных 5% оценка все равно не дотягивает. Это нормально: у десяти игроков остается индивидуальный шум, который ни один метод убрать не может. Коррекция уменьшает шум, а не отменяет его.



Три способа рядом. Слева направо разброс сжимается с 63,3 до 10,2 и далее до 5,2 минуты, а разница между средними групп меняет знак на верный.

Что остается обязательным

Все признаки должны быть известны до начала теста. Устройство известно, оно фиксируется при установке. А вот уровень игрока на конец теста брать нельзя: изменение могло на него повлиять, и поправка вычтет часть настоящего эффекта. Формула подбирается по всем игрокам сразу и не знает, кто в какой группе. Если дать модели признак группы, она начнет объяснять ту самую разницу, которую мы измеряем, и эффект из данных исчезнет.

Почему больше признаков не всегда лучше

Каждый признак добавляет в формулу коэффициент, который оценивается по тем же данным. При малом числе наблюдений коэффициенты сами становятся шумными, и выигрыш съедается. В этом примере десять игроков и три коэффициента — соотношение заведомо оптимистичное, поэтому разброс упал так сильно.
На реальных данных статьи, где восемь тысяч игроков, переход от одного признака к семи дал умеренное улучшение: остаточная дисперсия 0,410 вместо 0,453. Там же выяснилось, что замена линейной формулы градиентным бустингом выигрыша уже не приносит.

Связь со статьей

В статье этот способ называется линейной коррекцией и стоит третьей строкой в таблице результатов. Признаков там семь: предыстория, отметка об ее отсутствии, устройство, страна, уровень, число активных дней и принадлежность к гильдии.

Отметка об отсутствии предыстории — отдельная тема: именно она позволяет включить в анализ игроков, пришедших недавно, для которых X не существует. Механика у нее та же, что у отметки iOS в этом примере.