Промежуточный итог по ВКР

Как сделать A/B тесты в мобильных играх быстрее и точнее

МГТУ им. Н. Э. Баумана, кафедра ИУ5 · состояние на 21 сентября 2026

Рабочее название темы

«Разработка и исследование методов повышения чувствительности A/B экспериментов на метриках мобильных игр»

1. Работа в трех предложениях

Игровые компании проверяют каждое изменение в игре A/B тестом, но тесты идут долго, потому что поведение игроков очень разное и мешает разглядеть эффект. Существуют методы, которые убирают эту помеху, используя то, как игрок вел себя раньше, но они работают не всегда. Работа выясняет, **когда именно** эти методы помогают, и расширяет их на два трудных случая: игроков без истории и платежи, где почти всю выручку дают единицы.

2. Что такое A/B тест и в чем проблема

Допустим, разработчики добавили в игру ежедневную награду за вход и хотят понять, стали ли люди больше играть. Половине игроков награду включают (группа B), половине нет (группа A). Через неделю сравнивают, сколько играли те и другие. Группы формируются случайно, поэтому единственное систематическое различие между ними и есть наше изменение.

Проблема простыми словами

Игроки очень разные: один сидит в игре по три часа в день, другой заходит раз в неделю на десять минут. А эффект от изменения маленький, например плюс 5%. Это как пытаться услышать шепот на стадионе: шепот есть, но его заглушает гул толпы. Чтобы все-таки его расслышать, приходится набирать огромное число игроков и держать тест неделями. Это дорого и медленно.

3. Идея решения: учесть прошлое

Большая часть шума возникает из-за различий между людьми, а про эти различия мы кое-что знаем заранее: как каждый игрок вел себя **до** начала теста.

Аналогия

Нужно проверить, помогает ли витамин детям расти. Если просто сравнить рост детей через месяц, прибавка в 1 см потеряется: дети изначально разного роста. А если записать рост каждого до начала и смотреть на прибавку, разница становится видна. Методы, которые мы изучаем, делают то же самое, только аккуратнее.

Метод CUPED

Для каждого игрока берем его показатель до теста X (например, время в игре за две недели до старта) и показатель во время теста Y. Из Y вычитаем ту часть, которую можно было предсказать по X, и сравниваем группы уже по скорректированным числам:

$$Y_{\text{скорр}} = Y - \theta\,(X - X_{\text{ср}})$$

Коэффициент θ показывает, насколько сильно прошлое связано с настоящим. В среднем разница между группами от такой поправки не меняется, а шум уменьшается. Насколько сильно, зависит от корреляции ρ между прошлым и настоящим: шум умножается на

$$1 - \rho^2$$

Например, при ρ = 0.8 шум падает почти втрое, и во столько же раз меньше нужно игроков. При ρ = 0.3 выигрыш всего около 9%.

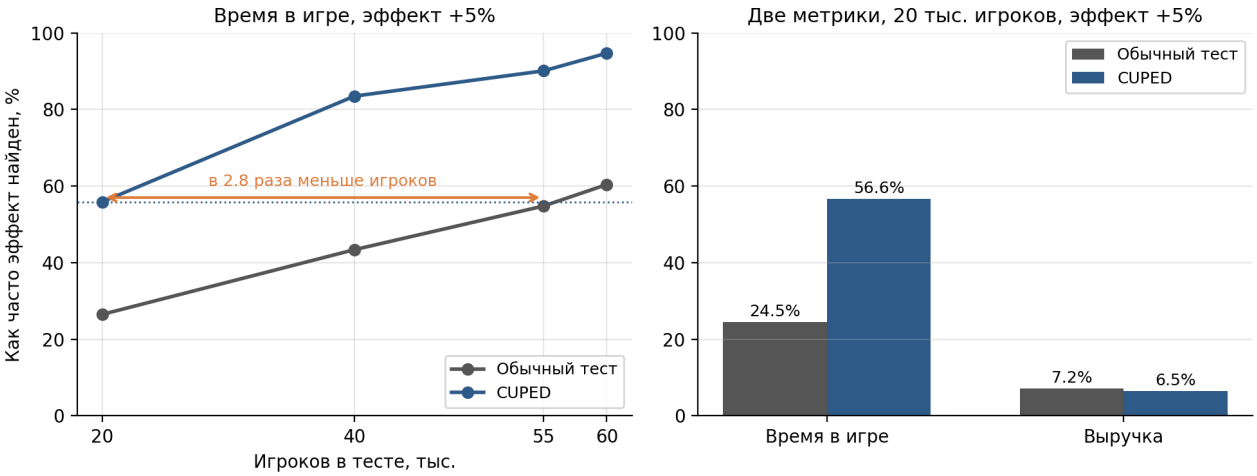
Метод CUPAC

Прошлое значение показателя не единственное, что мы знаем об игроке. Есть уровень, устройство, страна, давность регистрации, число сессий. CUPAC обучает модель машинного обучения, которая по всем этим признакам предсказывает будущий показатель игрока, и подставляет это предсказание вместо X в ту же формулу. По сути CUPED это простейший частный случай CUPAC, где модель использует один признак.

> **Главное условие**
>
> Все, что используется для поправки, должно быть известно **до** начала теста. Если взять данные, на которые уже повлияло изменение, метод вычтет часть настоящего эффекта и даст неверный ответ. Это обязательно показать в работе отдельным экспериментом.

4. Что уже проверено

Чтобы оценить метод честно, нужно знать правильный ответ, а в реальных данных его никто не знает. Поэтому я сгенерировал 20 000 виртуальных игроков с устойчивыми привычками и **сам** добавил половине из них эффект заданного размера. Затем повторил эксперимент 2000 раз и посчитал, в какой доле случаев каждый способ находит заложенный эффект. Эта доля называется мощностью.



Левый график построен по отдельной серии повторов, поэтому значения при 20 тыс. игроков немного отличаются от таблицы ниже. Это обычный случайный разброс самой симуляции.

Результат для времени в игре

Заложенный эффект	Обычный тест	CUPED
+3%	13.0%	24.8%
+5%	24.5%	56.6%
+10%	68.5%	96.7%

Корреляция прошлого и настоящего 0.80, шум упал на 64%. Чтобы догнать CUPED, обычному тесту нужно около 55 тыс. игроков вместо 20 тыс., то есть тест можно сократить примерно в 2.8 раза. Это совпадает с теоретическим расчетом.

Результат для выручки

Корреляция всего 0.33, шум упал на 12%, выигрыша почти нет: при эффекте +5% оба способа находят его примерно в 7% случаев. Причина в природе платежей: сколько человек играет, это привычка, а заплатит ли он на этой неделе, почти лотерея. Прошлое тут мало что подсказывает.

Проверка на честность

Метод мог бы «находить» эффект везде, в том числе там, где его нет. Поэтому проведены A/A тесты: 2000 экспериментов, где обе группы одинаковы. Честный метод ошибается примерно в 5% случаев. Получилось от 4.0% до 5.6% у обоих способов, то есть CUPED не подкручивает результат, а действительно убирает шум.

Вывод

Метод не универсален. Он помогает ровно тогда, когда прошлое поведение игрока предсказывает будущее: для времени в игре выигрыш почти втрое, для выручки его нет. Это условие можно проверить до запуска теста.

Оговорка

Это придуманные данные, и связь прошлого с настоящим в них задал я сам. Поэтому такой результат доказывает работоспособность подхода, но не то, что он сработает на настоящих играх. Для этого в работе нужны реальные данные (раздел 6).

5. Две задачи, ради которых пишется работа

Просто применить известный метод к данным недостаточно для диплома. Собственный вклад работы в том, чтобы снять два ограничения метода.

Часть A. Новички без истории

CUPED требует данных до теста, а в играх много новых игроков, у которых истории просто нет. Для них поправка неприменима. Нужно выяснить, чем ее заменить: признаками, известными в момент установки (устройство, страна, откуда пришел), отдельной моделью для новичков или одной общей моделью. И проверить, что ни один из вариантов не искажает результат.

Часть B. Тяжелые хвосты

В играх платит небольшая доля игроков, а основную выручку дают единицы очень крупных плательщиков. На таких данных само среднее значение неустойчиво, обычный тест может работать некорректно, а оценка коэффициента θ ломается от выбросов. Нужно понять, как совместить обработку выбросов со снижением шума и не потерять при этом смысл метрики: если обрезать крупных плательщиков, можно отрезать и главный эффект.

	Часть A: новички	Часть B: тяжелые хвосты
Сложность	Средняя	Высокая
Риск не получить результат	Низкий	Выше
Когда в плане	Ноябрь — декабрь	Февраль — март

6. Данные

Готового публичного датасета, где было бы все сразу (игра, случайное разбиение, история игроков и выручка), найти не удалось: игровые компании такими данными почти не делятся. Решение в том, чтобы использовать несколько источников, каждый из которых закрывает свою часть задачи.

Важная идея: полусинтетический эксперимент

Настоящий A/B тест для проверки метода не обязателен. Достаточно реальной истории игроков за длительный период. Берем, например, 4 недели: первые 2 считаем периодом до теста, игроков случайно делим на группы, а во вторые 2 недели сами добавляем группе B известный эффект. Распределения и привычки игроков настоящие, а правильный ответ известен.

Источник	Что в нем есть	Для чего
Симулятор	Любые заданные условия, известный эффект	Проверка при известной правде и в условиях, которых нет в реальных данных
WoWAH (World of Warcraft)	91 тыс. персонажей, время в игре за 3 года	CUPED и CUPAC на реальной игровой истории, новички (часть A)
Cookie Cats	Реальный A/B тест в мобильной игре, 90 тыс. новых игроков	Реальное случайное разбиение, A/A тесты, часть A
Hillstrom	Реальный эксперимент в ритейле: 64 тыс. клиентов, траты до и после	Тяжелый хвост трат на настоящем эксперименте с историей (часть B)
Uken Games	300 тыс. игроков с выручкой; доступ нужно запрашивать	Игровая выручка для части B, если удастся получить

Использовать несколько источников в одной работе нормально: работа исследует методы, а датасеты служат испытательными стендами. Метод, проверенный в разных условиях, убедительнее метода, проверенного в одних. Главное, чтобы у каждого источника была ясная роль и ко всем применялась одна и та же процедура оценки.

Ограничение, которое честно указывается в работе: выводы по Hillstrom относятся к ритейлу, а не к играм, поэтому их перенос на игры подкрепляется симуляцией. Лучший вариант, если на преддипломной практике удастся получить обезличенные данные реальной игры.

7. Что получится в итоге

Программа для анализа A/B тестов

На вход подается таблица: игрок, его группа, показатель во время теста и данные о нем до теста. Программа не привязана к конкретной игре и принимает любые числовые показатели. На выходе:

- результат теста обычным способом;
- результат с поправкой на прошлое игроков, с более узким интервалом;
- оценка выигрыша: во сколько раз можно было сократить тест;
- проверки данных: например, предупреждение, если данные «до теста» на самом деле собраны после его начала;
- прогноз до запуска теста: стоит ли вообще применять метод на этих данных.

Выводы исследования

Ожидаемый вид главного результата: «на метриках такого типа метод X сокращает нужную выборку в N раз без роста ложных срабатываний, а в таких-то условиях не помогает». Отрицательный результат, например для выручки, тоже ценен, если он честно измерен и объяснен.

8. Цель и задачи (для утверждения темы)

Цель. Сократить требуемый объем выборки и продолжительность A/B экспериментов на метриках мобильных игр за счет расширения области применимости методов ковариатной коррекции.

Задачи.

1. Проанализировать методы снижения дисперсии оценок в контролируемых экспериментах и выявить ограничения их применимости.
2. Обосновать условия несмещенности оценки эффекта при ковариатной коррекции.
3. Разработать и откалибровать генератор синтетических данных, воспроизводящий характеристики игровых метрик.
4. Предложить способ коррекции для пользователей с отсутствующей предэкспериментальной историей.
5. Исследовать совместное применение методов обработки тяжелохвостых распределений и снижения дисперсии.
6. Разработать методику сравнения и провести эксперименты по оценке уровня значимости, мощности и требуемого объема выборки.
7. Проверить полученные результаты на реальных наборах данных.
8. Разработать программное средство, реализующее предложенный подход.

9. План на год

Период	Что делаем
Сентябрь — октябрь	Обзор литературы, теория, первая версия симулятора и методики экспериментов. Поиск и загрузка данных.
Ноябрь — декабрь	Часть A: новички без истории. Подключение CUPAC.
Январь	Сессия. Показ результатов части A руководителю, согласование объема части B.
Февраль — март	Часть B: тяжелые хвосты и их сочетание со снижением шума.
Апрель	Проверка на реальных данных, доведение программы: проверки, отчет, тесты, документация.
Май — июнь	Оформление записки, доклад, предзащита, нормоконтроль, защита.

Реального времени на исследование около 7–8 месяцев: параллельно идет учеба, а последние полтора-два месяца уходят на оформление. Сроки нужно сверить с графиком кафедры.

10. Ближайшие шаги

- Скачать WoWAH (полную версию с сайта авторов) и Cookie Cats.
- Написать организаторам кейса Uken Games с вопросом о доступе к данным для ВКР.
- Загрузить Hillstrom и посчитать, насколько траты за прошлый год связаны с тратами после рассылки. Это первая реальная оценка того, сколько даст CUPED на выручке.
- Завести журнал экспериментов: для каждого запуска параметры, результат и вывод.
- Писать текст записки по ходу работы, а не в конце.

Что уточнить у руководителя

- Подходит ли рабочее название и формулировка цели и задач.
- Допустимо ли проверять методы на нескольких открытых наборах данных и на симуляции.
- Требования кафедры к объему, обязательным разделам и программной части.
- Есть ли возможность получить реальные игровые данные через практику.

Словарик

Термин	Простыми словами
A/B тест	Сравнение двух случайных групп пользователей: одна видит старую версию, другая новую.
Метрика	Число, по которому судим об успехе: время в игре, выручка, доля вернувшихся игроков.
Шум, дисперсия	Разброс значений между игроками, который мешает разглядеть эффект.
Корреляция	Насколько одно число связано с другим. От 0 (никак) до 1 (полностью).
Мощность	Как часто тест находит эффект, если он действительно есть.
Ложное срабатывание	Тест «нашел» эффект, которого нет. Допустимая доля обычно 5%.
A/A тест	Проверка метода на двух одинаковых группах, где эффекта заведомо нет.
Тяжелый хвост	Ситуация, когда редкие огромные значения (крупные плательщики) сильно влияют на среднее.
Симуляция	Искусственные данные, сгенерированные по заданным правилам, с известным правильным ответом.
Полусинтетический эксперимент	Реальные данные игроков, в которые искусственно добавлен известный эффект.